


Modelado Supervisado y No Supervisado en Ciencia de Datos Futbolística

Práctico 3: Marco Conceptual y Aplicación Práctica

Mentor: Ing. Guillermo Alonso

Córdoba, Argentina 2026

La Hoja de Ruta: Del Dato Crudo al Scouting Inteligente



Hoy damos el salto definitivo: mamámo: convertir bases de datos históricas en herramientas predictivas y sistemas de scouting automatizado.

Las 3 Grandes Preguntas del Análisis Moderno



1. VALORACIÓN:
¿Cómo medimos el
impacto del 99% de
las acciones que no
terminan en un
remate o asistencia
directa?



2. PERFILES:
¿Cómo descubrimos
el estilo de juego
real de un
futbolista sin
depender de
etiquetas o posiciones
subjetivas?




3. SCOUTING:
¿Cómo encontramos
matemáticamente al
reemplazo perfecto
para una estrella
utilizando
similitud
vectorial?

PARTE A

Aprendizaje Supervisado:
El Valor de la Acción

Expected Threat (xT): El Tablero Espacial

El modelo xT (Karun Singh) evalúa el peligro inminente de cada metro cuadrado del campo mediante un Proceso iterativo de Markov.




$P(\text{shoot}) \times P(\text{goal})$: La probabilidad de rematar y anotar desde esa zona específica.

$P(\text{move})$: La probabilidad de trasladar o pasar el balón hacia una nueva zona.

Value Iteration: El modelo converge iterativamente hasta asignar un valor de 'Amenaza Esperada' a cada una de las 192 celdas.

$$\text{Valor de la Acción} = xT(\text{Destino}) - xT(\text{Origen})$$

Anatomía de la Amenaza: Premier League 2017/18




Izquierda: La grilla final de xT resalta los 'half-spaces' y los vértices del área chica.

Centro/Derecha: La descomposición probabilística revela que $P(\text{shoot})$ domina la frontal del área, mientras que $P(\text{goal})$ castiga severamente los ángulos cerrados.

Framework VAEP: Contexto y Cadenas de Acciones

Valuing Actions by Estimating Probabilities (VAEP) utiliza clasificadores XGBoost y LightGBM sobre datos SPADL para proyectar el riesgo y la recompensa de las próximas 10 acciones.

P(score): Aumento en la probabilidad de que nuestro equipo anote (Genera Valor Ofensivo).



P(concede): Disminución en la probabilidad de que el rival anote (Genera Valor Defensivo).

$$\text{VAEP}(a) = \Delta P(\text{score}) - \Delta P(\text{concede})$$


Diagnóstico Comparativo: xT vs. VAEP

Dimensión	Expected Threat (xT)	VAEP Framework
Enfoque Principal	Basado en coordenadas espaciales	Basado en secuencia de eventos
Fase de Juego	Solo Ofensiva ❌	Ofensiva y Defensiva ✅
Contexto Histórico	Memoria Corta (Markov)	Últimas 3 acciones
Algoritmo Base	Programación Dinámica	Machine Learning (Boosting)
Sensibilidad al Error	Ignora pérdidas de balón ❌	Castiga los errores drásticamente ✅

Correlación ($r \approx 0.66$): Ambos modelos coinciden en creadores de juego, pero divergen totalmente al evaluar centrales y mediocentros defensivos.


Mapeo de Valor: Ofensiva vs. Defensiva

Al agregar el VAEP por 90 minutos, el modelo separa naturalmente los perfiles tácticos.




Abriendo la Caja Negra: Explicabilidad con SHAP

Impacto Global (Beeswarm)



Distancia al arco, ángulo y éxito de la acción dominan globalmente la arquitectura del XGBoost para **P(score)**.

Impacto Local (Waterfall)



Auditamos jugadas individuales. En este remate específico, la variable **actiontype_shot** aportó **+1.08** a la probabilidad, pero el ángulo desfavorable restó impacto.




PARTE B

Aprendizaje No Supervisado: Perfiles y Scouting


Clustering K-Means: Descubriendo Perfiles Tácticos

Selección Matemática de K



El Método del Codo y el Silhouette Score determinan matemáticamente que K=4 es la partición óptima.


Identidad de los Clusters



- El mapa de calor revela arquetipos tácticos puros:
 - C0**: Centrales y recuperadores (Clearance/Pass)
 - C1**: Distribuidores (Pass dominante)
 - C2**: Extremos (Cross/Dribble)
 - C3**: Finalizadores (Shot)

Reducción Dimensional: El Mapa Espacial UMAP

Proyectamos 21 dimensiones a un mapa 2D comprensible utilizando Uniform Manifold Approximation and Projection (UMAP).




¿Por qué UMAP frente a t-SNE o PCA?

Porque **preserva simultáneamente la estructura local y la topología global.**

Revela un espectro continuo donde los jugadores **transicionan fluidamente entre roles tácticos**, sin aislarse en cajas rígidas.

Sistema de Scouting Automatizado por Similitud Coseno

¿Necesitamos un reemplazo con el mismo patrón exacto de decisiones? Calculamos la Similitud Coseno entre el vector del jugador objetivo y toda la base de datos de la liga.



Target: Jugador 3359
(L. Messi)

El sistema proyecta una red visual devolviendo un Top 10 automático de afinidad estilística (ej. Suárez 0.90, Griezmann 0.87).

Al cruzar esta similitud con VAEP, filtramos talento descubriendo perfiles infravalorados en el mercado.

El Desafío Práctico: Actividades Propuestas

1.

Grilla xT Extendida: Analizar el dilema Bias vs. Variance escalando la resolución a 32x24.

2.

Benchmarking LightGBM: Comparar velocidad, AUC y Brier Score frente al modelo XGBoost.

3.

Mapas de Action-Value Flow: Graficar vectores direccionales de alto VAEP sobre la cancha para visualizar zonas de peligro.

4.

Clustering Multi-liga: Identificar si los arquetipos tácticos de K-Means son universales o varían por país.

5.

Dashboard de Scouting: Consolidar similitud y métricas para proponer el reemplazo de una figura histórica.

Abrir `P3_Supervisado_NoSupervisado.ipynb` – Verificad dependencias (socceraction, shap, umap) y mantened el RANDOM_STATE. ¡Manos al código! Lanzando Jupyter_