DIPLODATOS 2026 · MENTORÍA · FAMAF-UNC

Ciencia de datos aplicada al fútbol

Hallazgos de los Prácticos 1 y 2

Ezequiel Ludueña · Farid Alvarez · Germán González · Marco Spalletti

Wyscout 2017/18 — Premier League, Serie A, La Liga

PUNTO DE PARTIDA

Qué tenemos entre manos

1,92 M

eventos crudos de Wyscout en tres ligas europeas

1.140

partidos de la temporada 2017/18

1.582

jugadores con al menos una acción registrada

3

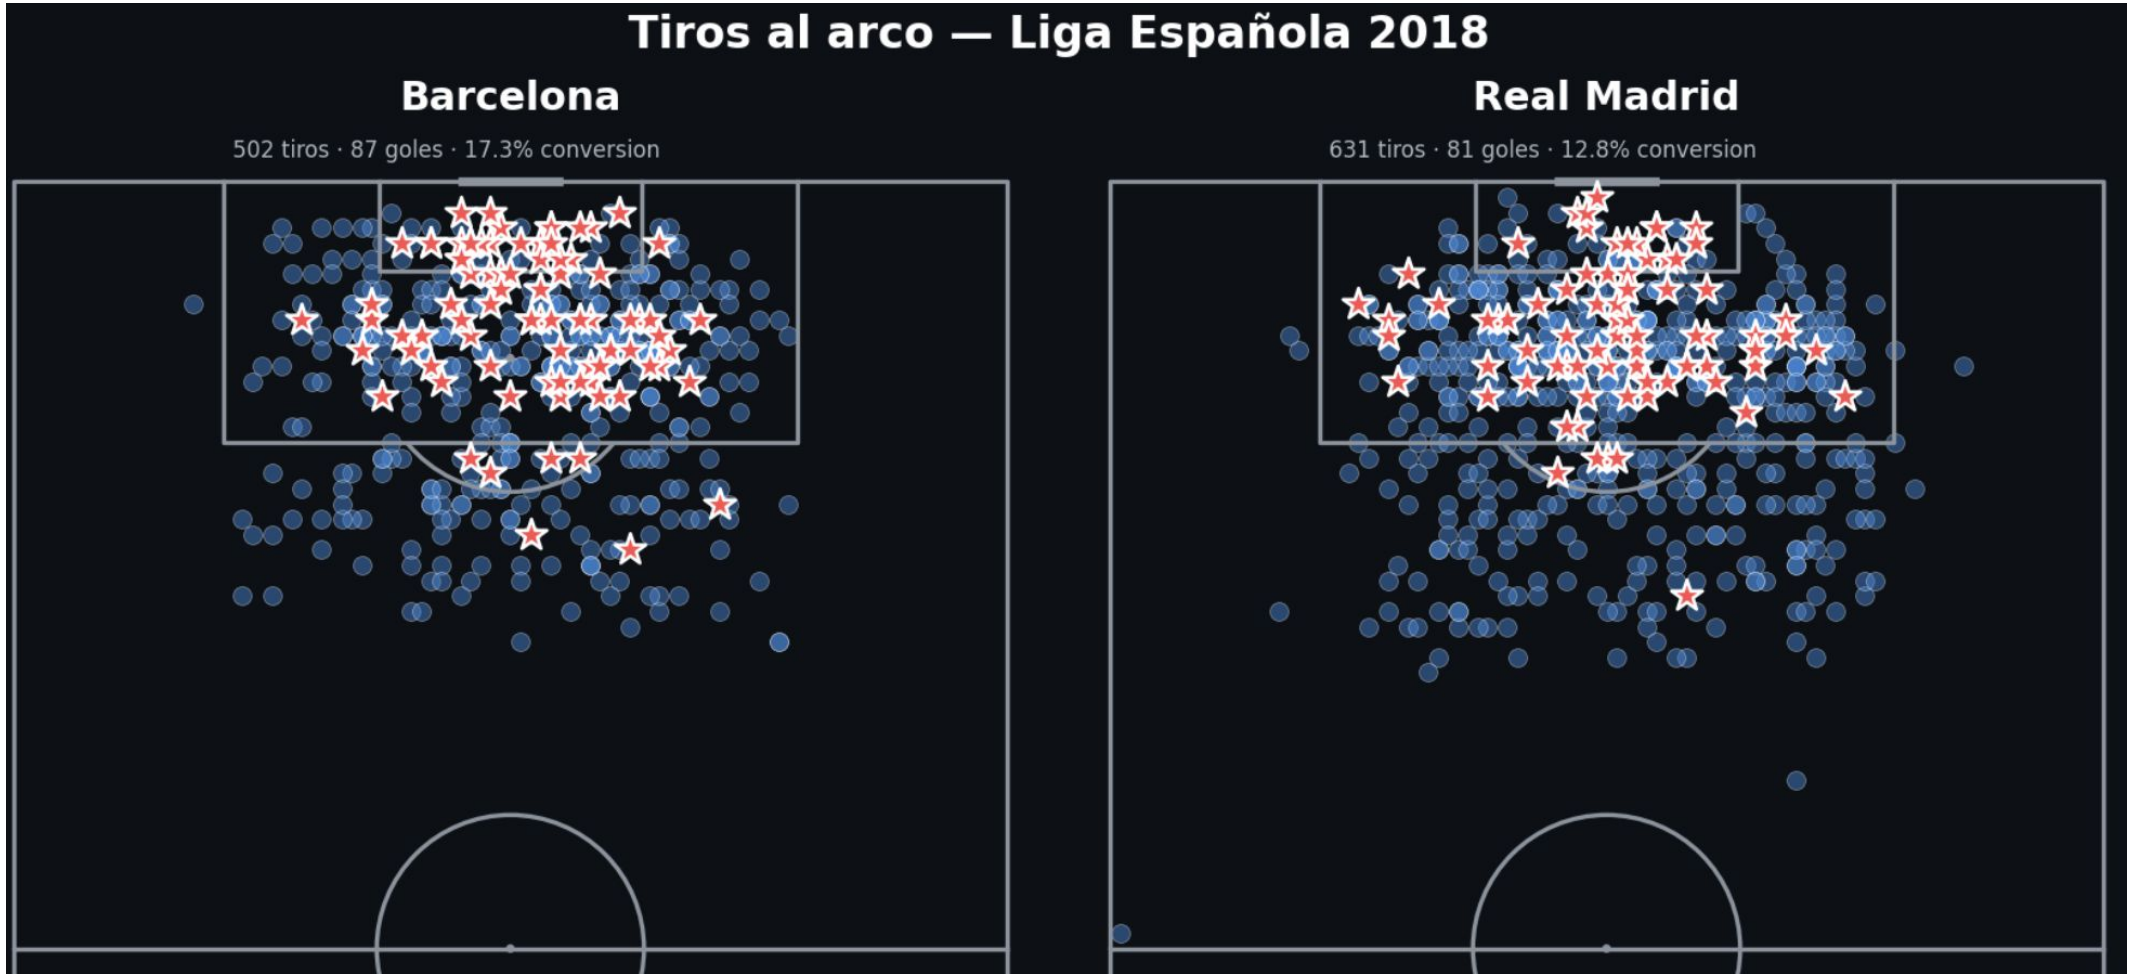
ligas: Premier League, Serie A y La Liga

El TP1 fue exploración y visualización sobre los eventos crudos.

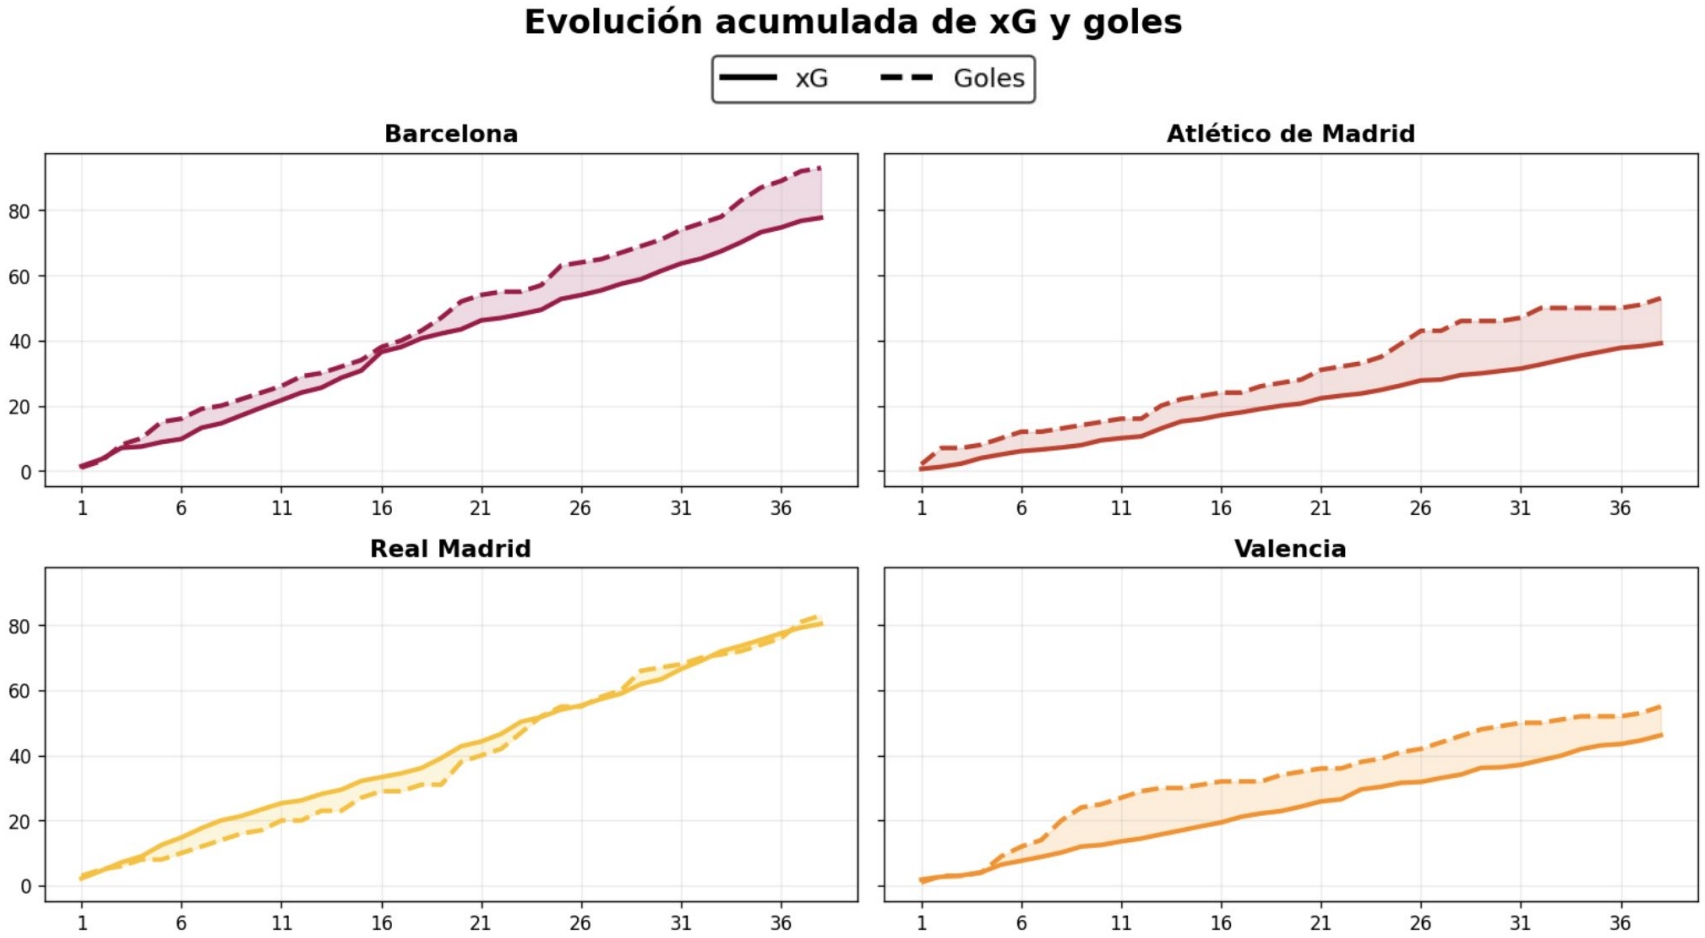
El TP2 convierte esos eventos al estándar SPADL — un vocabulario común de 18 tipos de acción — para que el dataset sea modelable en el TP3.

Lo que vimos en la exploración

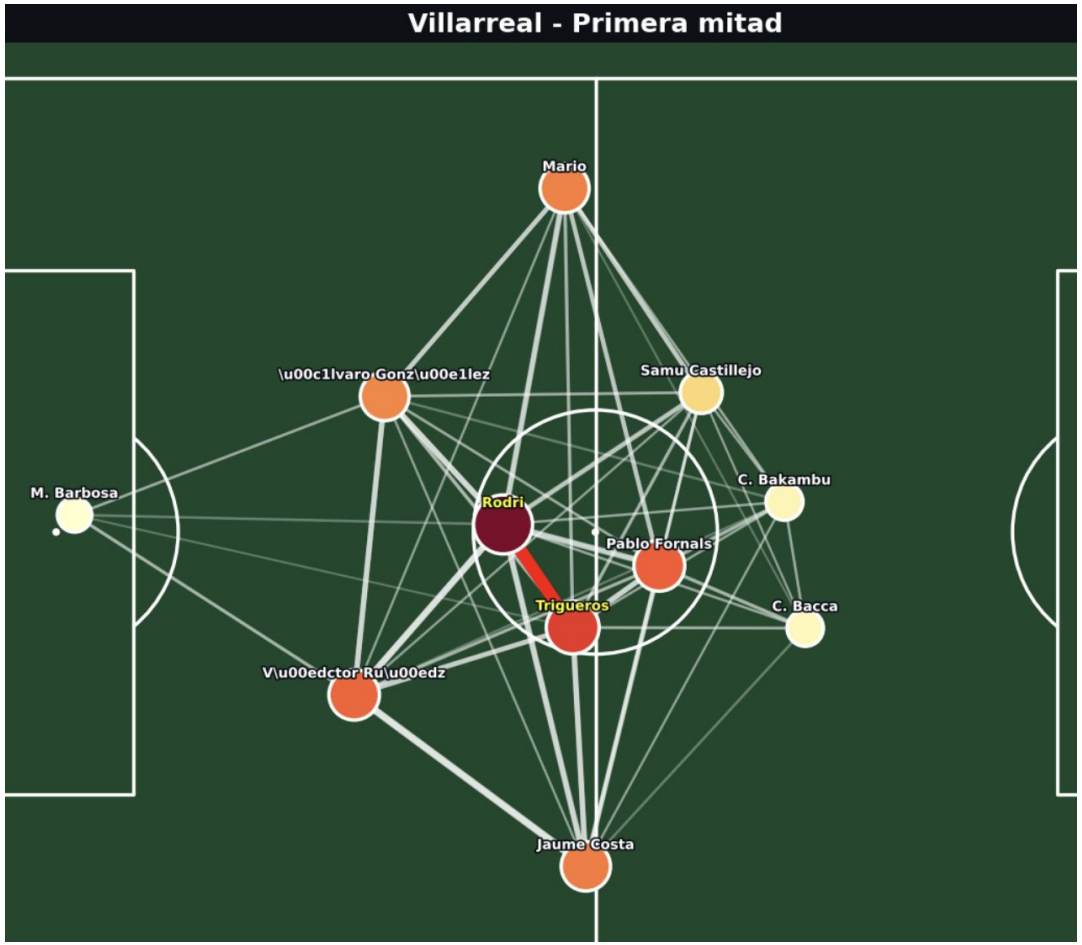
- **Más tiros no es más eficacia.** El Barcelona convirtió el 17,3% de sus remates y el Real Madrid el 12,8%, con el Real rematando más. El volumen y la eficiencia son cosas distintas.

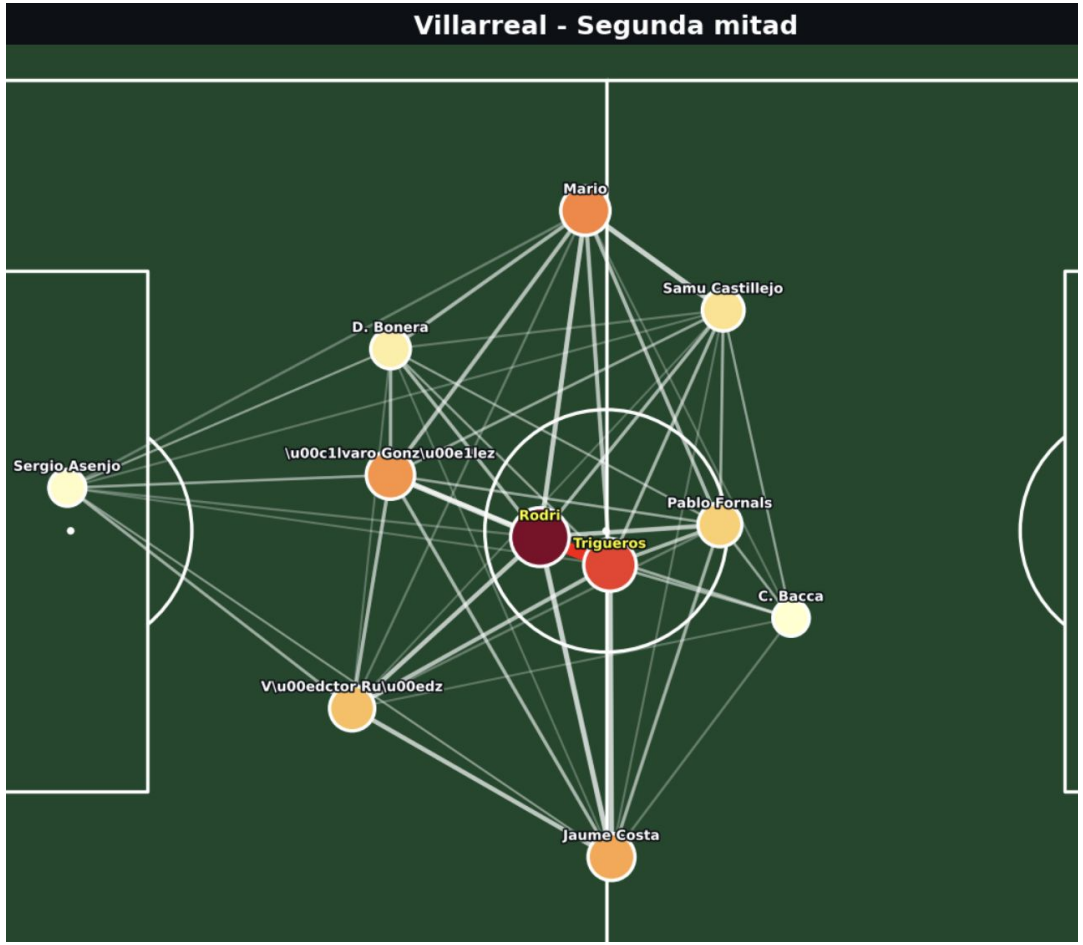


- **El xG nos muestra un potencial de producción (en goles); y la brecha respecto a los goles convertidos, muestra el aprovechamiento de las oportunidades:** El Barcelona convierte más goles de los esperados (sobre rendimiento), al igual que At. Madrid y Valencia; mientras que el Real Madrid presenta un sub rendimiento (menos goles que xG), y en la recta final del torneo las dos curvas están casi superpuestas.

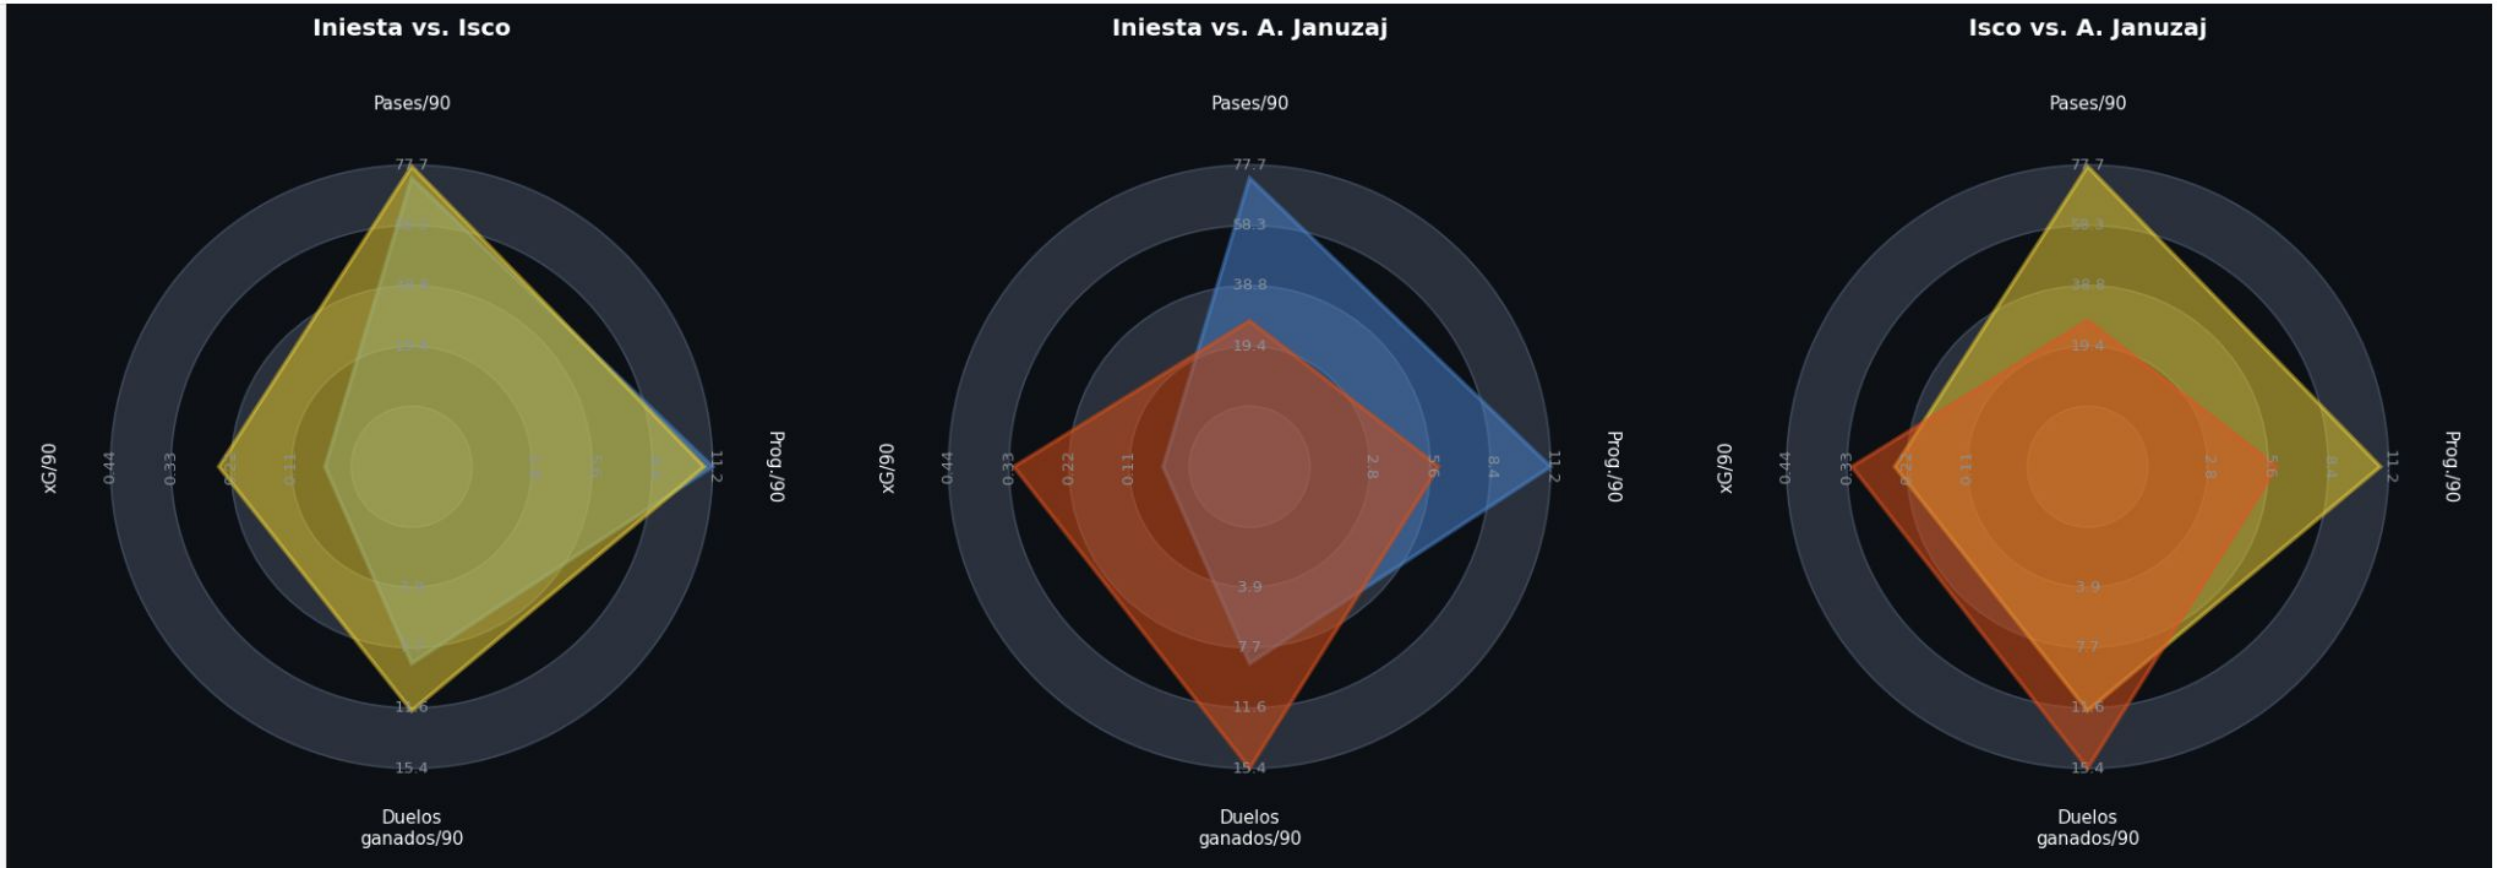


- **La red de pases dibuja la estructura táctica.** Se trabajó con el Villarreal, que mantiene consistencias a lo largo de la temporada: laterales abiertos y un mediocampo muy cargado y asociado, con Rodri y Trigueros como el par de mayor conexión de la temporada. En la primera mitad había dos delanteros centro, con Fornals más integrado al circuito de mediocampistas, mientras que en la segunda mitad, se observa la inclusión de un tercer defensor, y un mayor desprendimiento de los laterales y de Fornals

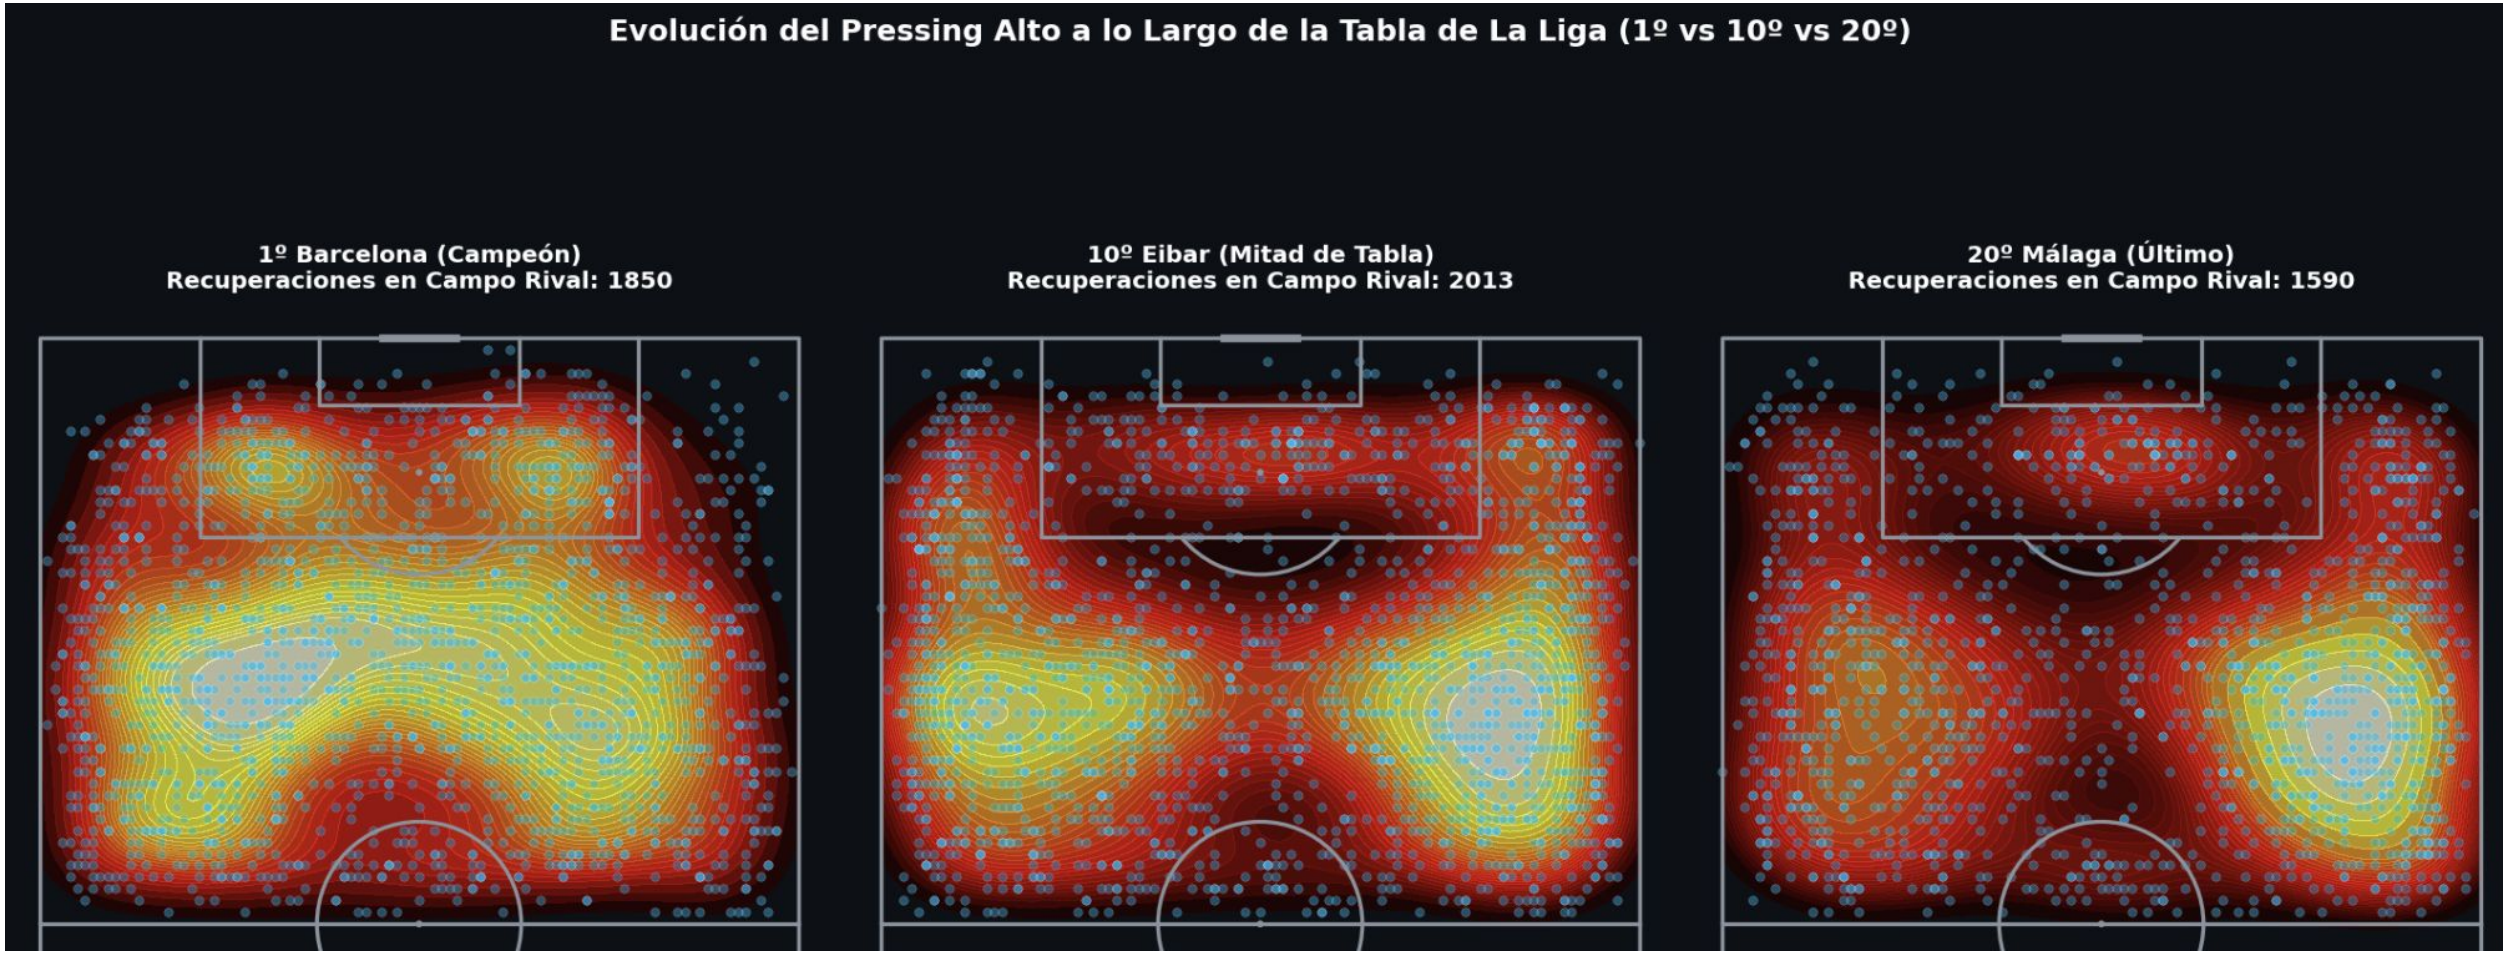




- **Los radares permiten una rápida e intuitiva comparación de jugadores en términos de las features seleccionadas:**
  Isco se destaca por ser un jugador todoterreno, incluso por encima de Iniesta (en términos de las variables analizadas), mientras que **Januzaj destaca más por los duelos ganados y su cercanía al gol**. Iniesta podría caracterizarse como un volante netamente creativo, Januzaj por los duelos ganados y sus capacidad para generar oportunidades de gol e Isco es el más completo de los 3.



- **El pressing es estilo, no jerarquía.** Barcelona (56,0%) y Eibar (56,2%) recuperan igual de arriba pese a terminar en zonas diferentes de la tabla. Todos recuperan una cantidad parecida: lo que cambia es dónde: Barcelona presenta un heatmap con puntos clave dentro del área pero sensiblemente cerca del área (donde también el xG si remata, es mayor), mientras que Eibar concentra sus recuperaciones en las bandas, donde el potencial peligro de las jugadas posteriores es menor).



PRÁCTICO 2

Correcciones en el pipeline de preprocesamiento y conversión al formato estándar

Nuestro trabajo consistió en la curación y corrección de detalles al convertir el dataset al formato Soccer Player Action Description Language (SPADL), estandarizado a nivel mundial en este campo.

Sin valores faltantes · sin outliers de coordenadas · sin duplicados · 100% de coordenadas válidas en las tres ligas

IMPACTO DE LAS CORRECCIONES

Qué cambió en el dataset

	Pipeline original	Pipeline corregido
Acciones totales	1.098.393	**1.454.564**
Sin coordenada de destino	991.522 (90,3%)	**0 (0,0%)**
Dribbles detectados	5.067	**115.523**
Acciones sin orientar en features	583.436 (48,4%)	**0**

Los otros siete tipos de acción mantienen exactamente el mismo conteo: las correcciones no inventan ni descartan eventos, recuperan información que el pipeline perdía.

100% de cobertura en los eventos

- **Eliminación de evento fuera de rango.** Si bien en la curación del dataset se encontró 1 evento que en sus coordenadas se encontraba fuera de rango, se tomó la decisión de eliminarlo, ya que no representaba una variabilidad significativa, entendiéndolo como un error de carga.

- **Cobertura total de los eventos.** De esta manera nos encontramos con que el total de los eventos habían sido cargados de manera válida.

- **Importancia de las ligas.** Vale aclarar que la comparación fue realizada sobre las tres principales ligas del mundo (Inglesa, Española e Italiana), por lo que sería interesante poder comprarlo con ligas que tengan el mismo tipo de cobertura, pero que sean de menor nivel, para corroborar si hay relación entre la profesionalidad de la liga y la cobertura de sus eventos

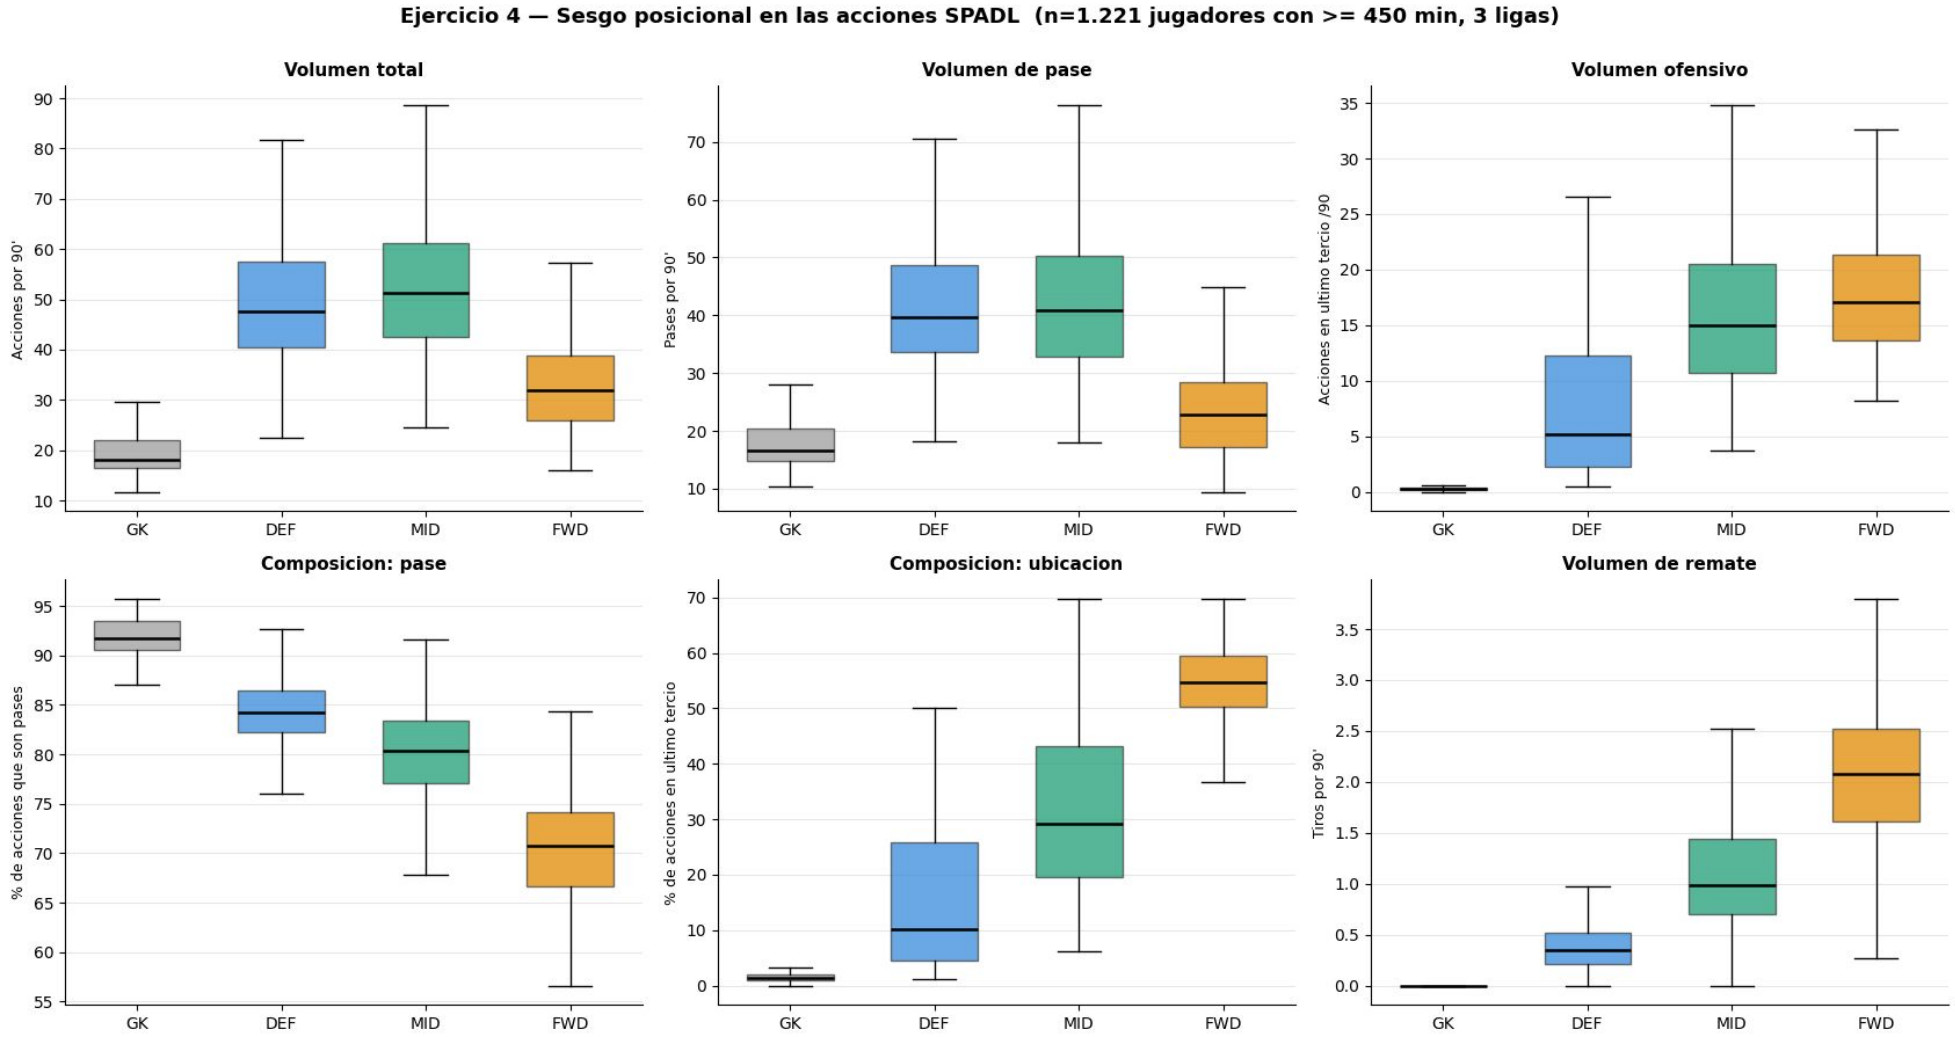
Distribución homogénea de los eventos

- **La cantidad de eventos se mantienen relativamente a lo largo del partido:** Con un promedio de aproximadamente 13 eventos por minuto de partido el número se mantiene a lo largo del partido con un muy pequeño descenso hacia el final del partido, lo cual podemos atribuir al cansancio acumulado

- **Anomalía entre los minutos 45 y 50.** Se observa un pico de eventos en dicho período, que supera los 20 eventos por minuto, pero que entendemos que tiene que ver con la superposición del suplemento del PT y los primeros minutos del ST

- **El gol como momento.** A diferencia de como intuíamos, el gol no cambia casi el volumen de eventos del partido antes y después del mismo, solamente en el minuto siguiente ya que se deja de jugar por festejos, reclamos arbitrales y reacomodamiento. Sería interesante aquí ver si el gol cambia el tipo de eventos que suceden en el partido, más allá de la cantidad.

Volumen y composición son ejes distintos



1.221 jugadores con 450+ minutos. Arriba, volumen por 90 minutos; abajo, composición del repertorio propio.

Tres respuestas, dos contraintuitivas

- **Sí hay sesgo, y es fuerte:** la posición explica el 41,5% de la varianza en volumen de acciones (ε^2=0,415).
- **Pero los delanteros registran MENOS acciones, no más.** 31,97 por 90' contra 51,34 de los mediocampistas — un 38% menos. La hipótesis de que “los ofensivos generan más eventos” no se sostiene en volumen.
- **Los delanteros sí dominan el último tercio, por concentración.** El 54,6% de sus acciones ocurre ahí, contra 29,2% de los mediocampistas. En volumen la ventaja es chica: no producen mucho más, producen casi solo eso.
- **Los mediocampistas NO hacen más pases que los defensores.** 40,80 contra 39,61 por 90': p=0,58, estadísticamente indistinguibles. Y en proporción los defensores pasan más (84,3% contra 80,4%).

El mediocampista tiene el repertorio más variado; el defensor hace menos cosas distintas y casi todo lo que hace es pasar.

Qué queda por delante

- **El dataset curado ya es modelable.** 1.204.377 acciones con cobertura completa de coordenadas y orientación consistente.

- **VAEP y xT sobre esta base.** Las 154 features de socceraction se recalculan sobre coordenadas correctas — antes, las de destino y movimiento estaban vacías en el 90% de los casos.

- **Normalizar por posición, no solo por minutos.** El sesgo de composición es el más fuerte de los dos y la normalización temporal no lo toca.

- **Umbral mínimo de acciones por jugador.** 402 de 1.582 jugadores tienen menos de 200 acciones: estimaciones de VAEP ruidosas si no se filtran.